

Outils d'optimisation pour les sciences des données et de la décision

Clément W. Royer

Notes de cours - M2 MIAGE - 2023/2024

- La version la plus récente de ces notes se trouve à l'adresse :
<https://www.lamsade.dauphine.fr/~croyer/ensdocs/ODD/PolyODD.pdf>.
- Pour tout commentaire, merci d'envoyer un mail à `clement.royer@lamsade.dauphine.fr`.
Merci à Sébastien Kerleau pour sa relecture attentive.
- **Historique du document**
 - 2023.09.21 : Mise à jour avec le contenu du premier cours.
 - 2023.09.15 : Première version.
- **Objectifs d'apprentissage**
 - Comprendre les caractéristiques des modèles d'optimisation les plus classiques.
 - Connaître les grands principes algorithmiques derrière la résolution de ces modèles.
 - Appliquer ces principes dans le contexte des sciences des données et de la décision.

Sommaire

1	Introduction à l'optimisation	5
1.1	Définition et contexte	5
1.1.1	Problème et processus d'optimisation	5
1.2	Logiciels et optimisation	6
1.3	Bases de l'optimisation mathématique	7
1.3.1	Formulation générale et premières définitions	7
1.3.2	Solutions et minima	9
1.3.3	Conditions d'optimalité	9
1.3.4	Cas des fonctions convexes	10
1.3.5	Cas des fonctions fortement convexes	12
1.4	Conclusion du chapitre 1	12
Annexe A	Bases mathématiques	13
A.1	Éléments d'algèbre linéaire	13
A.1.1	Algèbre linéaire vectorielle	13
A.1.2	Algèbre linéaire matricielle	15

Avant-propos

Le but de ce cours est de présenter les classes de problème d'optimisation les plus utilisés en finance, et les algorithmes associés à leur résolution. Il se veut découpé en plusieurs parties suivant le déroulement des séances de cours.

Ce cours n'est pas un cours de mathématiques, mais il repose sur plusieurs concepts élémentaires d'algèbre linéaire et de calcul différentiel. Ceux-ci ne seront pas rappelés en détail en cours, mais sont en revanche détaillés en annexe de ce polycopié. De même, les notations cruciales du polycopié sont décrites ci-après.

Notations

- Les scalaires seront représentés par des lettres minuscules : $a, b, c, \alpha, \beta, \gamma$.
- Les vecteurs seront représentés par des lettres minuscules **en gras** : $\mathbf{a}, \mathbf{b}, \mathbf{c}, \boldsymbol{\alpha}, \boldsymbol{\beta}, \boldsymbol{\gamma}$.
- Les lettres majuscules en gras seront utilisées pour les matrices : $\mathbf{A}, \mathbf{B}, \mathbf{C}$.
- Les lettres majuscules cursives seront utilisées pour les ensembles : $\mathcal{A}, \mathcal{B}, \mathcal{C}$.
- La définition d'une nouvelle quantité ou d'un nouvel opérateur sera indiquée par $:=$.
- L'ensemble des entiers naturels sera noté $\mathbb{N}$, l'ensemble des entiers relatifs sera noté $\mathbb{Z}$.
- L'ensemble des réels sera noté $\mathbb{R}$. L'ensemble des réels positifs sera noté $\mathbb{R}_+$ et l'ensemble des réels strictement positifs sera noté $\mathbb{R}_{++}$.
- On notera $\mathbb{R}^n$ l'ensemble des vecteurs à n composantes réelles, et on considèrera toujours que n est un entier supérieur ou égal à 1.
- Un vecteur $\mathbf{x} \in \mathbb{R}^n$ sera pensé (par convention) comme un vecteur colonne. On notera $x_i \in \mathbb{R}$ sa i -ème coordonnée dans la base canonique de $\mathbb{R}^n$. On aura ainsi $\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$. Étant donné un vecteur (colonne) $\mathbf{x} \in \mathbb{R}^n$, le vecteur ligne correspondant sera noté $\mathbf{x}^T$. On aura donc $\mathbf{x}^T = [x_1 \ \cdots \ x_n]$ et $[\mathbf{x}^T]^T = \mathbf{x}$.
- Le produit scalaire entre deux vecteurs de $\mathbb{R}^n$ est défini par $\mathbf{x}^T \mathbf{v} = \mathbf{v}^T \mathbf{x} = \sum_{i=1}^n x_i v_i$. On définit ensuite la norme d'un vecteur $\mathbf{x} \in \mathbb{R}^n$ par $\|\mathbf{x}\| = \sqrt{\mathbf{x}^T \mathbf{x}}$.
- On notera $\mathbb{R}^{m \times n}$ l'ensemble des matrices à m lignes et n colonnes à coefficients réels, où m et n seront des entiers supérieurs ou égaux à 1. Une matrice $\mathbf{A} \in \mathbb{R}^{n \times n}$ est dite carrée (dans le cas général, on parlera de matrice rectangulaire).
- On identifiera les vecteurs de $\mathbb{R}^n$ avec les matrices de $\mathbb{R}^{n \times 1}$.
- Étant donnée une matrice $\mathbf{A} \in \mathbb{R}^{m \times n}$, on notera $\mathbf{A}_{ij}$ le coefficient en ligne i et colonne j de la matrice. La diagonale de $\mathbf{A}$ est formée par l'ensemble des coefficients $\mathbf{A}_{ii}$ pour $i = 1, \dots, \min\{m, n\}$. La notation $[\mathbf{A}_{ij}]_{\substack{1 \leq i \leq m \\ 1 \leq j \leq n}}$ sera donc équivalente à $\mathbf{A}$. Sans ambiguïté sur la taille de la matrice, on notera simplement $[\mathbf{A}_{ij}]$.
- Selon les besoins, on utilisera $\mathbf{a}_i^T$ pour la i -ème ligne de $\mathbf{A}$ ou $\mathbf{a}_j$ pour la j -ème colonne de $\mathbf{A}$.
Selon le cas, on aura donc $\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^T \\ \vdots \\ \mathbf{a}_m^T \end{bmatrix}$ ou $\mathbf{A} = [\mathbf{a}_1 \ \cdots \ \mathbf{a}_n]$.
- Pour une matrice $\mathbf{A} = [\mathbf{A}_{ij}] \in \mathbb{R}^{m \times n}$, la matrice transposée de $\mathbf{A}$, notée $\mathbf{A}^T$, est la matrice de $\mathbb{R}^{n \times m}$ telle que
$$\forall i = 1 \dots m, \forall j = 1 \dots n, \quad \mathbf{A}_{ji}^T = \mathbf{A}_{ij}.$$
- Pour tout $n \geq 1$, $\mathbf{I}_n$ correspond à la matrice identité $\mathbb{R}^{n \times n}$ (avec 1 sur la diagonale et 0 ailleurs).

Chapitre 1

Introduction à l'optimisation

Le but de ce cours est de proposer une boîte à outils pour étudier et résoudre des problèmes d'optimisation, notamment dans le contexte moderne des sciences des données. En effet, de nombreuses tâches d'apprentissage peuvent en effet être formulées comme des problèmes d'optimisation, qui peuvent être ensuite résolus numériquement par des algorithmes dédiés. D'autres domaines d'application, comme la finance, ont aussi recours à l'optimisation pour modéliser et résoudre des problèmes tels que l'allocation de portefeuille.

Ce chapitre présente les principes de base derrière la formulation et l'étude (à la fois mathématique et algorithmique) d'un problème d'optimisation.

1.1 Définition et contexte

1.1.1 Problème et processus d'optimisation

Avant d'être un concept mathématique, un problème d'optimisation peut être verbalisé : on en donne une décomposition ci-dessous.

Définition 1.1.1 *Un problème d'optimisation mathématique est formé par les trois éléments suivants.*

- Une **fonction objectif** : il s'agit du critère qui permet de quantifier la qualité d'une décision. Selon le cas, une meilleure décision peut signifier une valeur de l'objectif plus faible (auquel cas on aura affaire à un problème de minimisation) ou plus élevée (il s'agira alors d'un problème de maximisation).
- Des **variables de décision** : ce sont les différents choix qu'il est possible d'effectuer, dont la valeur influence celle de la fonction objectif. On cherche les meilleures valeurs de ces variables relativement à l'objectif.
- Des **contraintes** : celles-ci spécifient des conditions qui doivent être satisfaites par les variables de décision pour que les valeurs correspondantes soient acceptables.

Tout processus d'optimisation passe nécessairement par une phase de **modélisation**, durant laquelle on transforme un problème concret en objet mathématique que l'on peut essayer de résoudre. Pour cela, on se base sur des **algorithmes d'optimisation** qui, bien que pouvant être formulés à la

main, ont généralement vocation à être implémentés sur un ordinateur. Lorsque l'algorithme appliqué au problème renvoie une réponse, celle-ci doit être examinée pour savoir si elle fournit une solution satisfaisante au problème : au besoin, le modèle pourra être modifié, et l'algorithme ré-exécuté. En pratique, le processus d'optimisation peut donc boucler après une phase d'**interprétation** ou de **discussion** avec des experts du domaine d'application dont le problème est issu.

Remarque 1.1.1 *L'optimisation numérique obéit généralement aux principes suivants :*

- *Il n'y a pas d'algorithme universel : certaines méthodes seront très efficaces sur certains types de problèmes, et peu efficaces sur d'autres. L'étude de la structure du problème facilite le choix d'un algorithme.*
- *Il peut y avoir un fort écart entre la théorie et la pratique : le calcul en précision finie peut induire des erreurs d'arrondis qui conduisent à une performance en-deçà de celle prévue par la théorie mathématique.*
- *La théorie guide la pratique, et vice-versa : pour la plupart des problèmes, il est possible de définir des expressions mathématiques qui permettent de vérifier si l'on a trouvé une solution du problème. Celles-ci sont à la base de nombreux algorithmes que nous étudierons. De manière générale, l'étude théorique d'un problème permet des avancées garanties qui surpassent souvent les heuristiques. Réciproquement, la performance de certaines méthodes a amené les chercheurs en optimisation à en proposer une étude théorique, permettant ainsi d'expliquer le comportement pratique.*

Optimisation en finance L'optimisation est utilisée en finance comme un outil de modélisation et de résolution efficace de problèmes. Dans ce contexte, on retrouve notamment des problèmes de programmation linéaire ou quadratique, dont le fameux problème d'allocation de portefeuille dû à Markowitz. Durant la dernière décennie et suite à la crise dite des *subprimes* de 2007-2008, la réglementation sur les niveaux de risques autorisés dans les milieux financiers a considérablement évolué. Les opérations financières sont aujourd'hui exécutées. En termes d'optimisation, cela a conduit au développement de problèmes sous contraintes de niveau de risque, avec une prise en compte accrue de l'aléatoire.

Optimisation en sciences des données En sciences des données, les problèmes d'optimisation impliquent souvent l'utilisation d'un ensemble massif de données dans la définition de la fonction objectif. On cherche ainsi à construire un modèle ou une prédiction sur la base d'un échantillon, qui n'est pas nécessairement un reflet exact de la distribution sous-jacente des données. Dans un contexte de données potentiellement distribuées, dont le coût d'utilisation peut être drastiquement élevé, les algorithmes d'optimisation ne sont pas tous égaux : de fait, certains algorithmes ayant fait leurs preuves dans des contextes basés sur des modèles s'avèrent peu performants dans ce contexte guidé par les données (ou *data-driven*).

1.2 Logiciels et optimisation

L'optimisation a connu un essor majeur au cours des années 1980 avec le développement des ordinateurs. Une composante majeure

Les langages de programmation les plus utilisés pour développer des algorithmes d'optimisation étaient historiquement C/C++/Fortran, notamment pour développer des codes performants. Le développement de prototypes de recherche se fait lui plutôt via des langages interprétés tels que Matlab/Octave/Python/Julia, avec Python prenant de plus en plus d'importance de par son utilisation dans les problèmes de sciences des données et apprentissage.

En plus des langages de programmation standard, de nombreux langages ou bibliothèques ont été développés pour modéliser les problèmes d'optimisation. On peut citer notamment GAMS, AMPL, CVX, Pyomo, qui ont un champ d'application génériques, ou MATPOWER et PyTorch, qui sont dédiés à un domaine particulier (respectivement les réseaux d'énergie et l'apprentissage machine).

D'autres outils plus bas niveau ont également été développés, parfois avec un spectre plus large d'applications. Le logiciel MATLAB (propriétaire) dispose ainsi d'une boîte à outils de finance très fournie, qui comporte notamment des algorithmes d'optimisation. On s'intéressera dans ce cours à la bibliothèque cvxpy, développée à l'origine à l'université de Stanford (États-Unis), et qui dispose de nombreux outils pour résoudre les problèmes de programmation convexe.

En finance Dans le contexte de la finance, le recours aux tableurs est prépondérant, ce qui a conduit au développement de solveurs en tant qu'outil interne aux tableurs. C'est ainsi que Microsoft Excel, LibreOffice Calc et Google Sheets possèdent des solveurs, notamment de programmation linéaire. Si certains sont disponibles gratuitement (*open source*), le solveur le plus abouti (Microsoft Excel Solver) requiert une licence d'exploitation.

En sciences des données Python est maintenant le langage dominant. Outre la bibliothèque scipy standard, les bibliothèques scikit-learn, TensorFlow et PyTorch (ou plus récemment JAX) contiennent des algorithmes d'optimisation adaptés aux problèmes de sciences des données.

1.3 Bases de l'optimisation mathématique

1.3.1 Formulation générale et premières définitions

La transformation d'une description formelle d'un problème d'optimisation en objet mathématique conduit à l'écriture suivante :

$$\underset{x \in \mathbb{R}^n}{\text{minimiser}} f(x) \quad \text{s.c.} \quad x \in \mathcal{X}, \quad (1.3.1)$$

où minimiser représente ce que l'on cherche à faire (on peut vouloir minimiser ou maximiser), $x \in \mathbb{R}^n$ est un vecteur regroupant les variables de décision du problème, $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est la fonction objectif qui mesure la qualité des décisions, et $\mathcal{X} \subset \mathbb{R}^n$ est l'ensemble des points réalisables ou admissibles, qui vérifient les contraintes posées sur les variables de décision. ¹

Définition 1.3.1 i) Un point $x \in \mathbb{R}^n$ tel que $x \in \mathcal{X}$ est dit **admissible**, ou **réalisable**.

ii) Un point $x \in \mathbb{R}^n$ tel que $x \notin \mathcal{X}$ est dit **irréalisable**.

iii) Si $\mathcal{X} = \emptyset$, alors le problème (1.3.1) est dit **irréalisable**.

¹L'abréviation s.c. signifie "sous la/les contrainte(s)"; en anglais, on utilise s.t., pour *subject to*.

Définition 1.3.2 i) La *valeur minimale* (ou le *minimum*) du problème (1.3.1) est notée :

$$\min_{\mathbf{x} \in \mathbb{R}^n} \{f(\mathbf{x}) \text{ s.c. } \mathbf{x} \in \mathcal{X}\}. \quad (1.3.2)$$

Lorsque le problème possède une solution, la valeur minimale est la valeur de f en toute solution, et cette valeur est finie. Lorsque le problème est irréalisable, on pose par convention

$$\min_{\mathbf{x} \in \mathbb{R}^n} \{f(\mathbf{x}) \text{ s.c. } \mathbf{x} \in \mathcal{X}\} = +\infty.$$

Enfin, si le problème est réalisable mais qu'il n'existe pas de solution, on aura

$$\min_{\mathbf{x} \in \mathbb{R}^n} \{f(\mathbf{x}) \text{ s.c. } \mathbf{x} \in \mathcal{X}\} = -\infty,$$

et on dit alors que le problème est **non borné**.

ii) L'ensemble des solutions du problème (1.3.1) est noté

$$\operatorname{argmin}_{\mathbf{x} \in \mathbb{R}^n} \{f(\mathbf{x}) \text{ s.c. } \mathbf{x} \in \mathcal{X}\}, \quad (1.3.3)$$

qu'on appelle argument minimal (ou *argmin*) du problème. C'est un sous-ensemble de $\mathbb{R}^n$ (et de $\mathcal{X}$) : il s'agit de l'ensemble des points de $\mathcal{X}$ qui donnent la valeur minimale de f . Il est vide si le problème est irréalisable ou réalisable et non borné.

Remarque 1.3.1 Le problème (1.3.1) n'admet pas forcément de solution (prendre par exemple $d = 1$, $\mathcal{F} = \mathbb{R}$ et $f(w) = w$) : dans ce cas, l'argument minimal est l'ensemble vide, et la valeur minimale est $-\infty$.

On définit de la même manière que précédemment les problèmes de maximisation ainsi que les opérateurs argmax et $\max$. Dans ce cours, on se concentrera sur les problèmes de minimisation, utilisant en cela la propriété ci-dessous.

Proposition 1.3.1 Pour toute fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ et tout ensemble $\mathcal{F} \subset \mathbb{R}^n$, résoudre le problème de maximisation

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{s.c. } \mathbf{x} \in \mathcal{F}$$

équivalent à résoudre le problème de minimisation

$$\min_{\mathbf{x} \in \mathbb{R}^n} -f(\mathbf{x}) \quad \text{s.c. } \mathbf{x} \in \mathcal{F},$$

dans la mesure où

$$\operatorname{argmax}_{\mathbf{x} \in \mathbb{R}^n} \{f(\mathbf{x}) \text{ s.c. } \mathbf{x} \in \mathcal{F}\} = \operatorname{argmin}_{\mathbf{x} \in \mathbb{R}^d} \{-f(\mathbf{x}) \text{ s.c. } \mathbf{x} \in \mathcal{F}\}$$

et

$$\max_{\mathbf{x} \in \mathbb{R}^n} \{f(\mathbf{x}) \text{ s.c. } \mathbf{x} \in \mathcal{F}\} = - \min_{\mathbf{x} \in \mathbb{R}^n} \{-f(\mathbf{x}) \text{ s.c. } \mathbf{x} \in \mathcal{F}\}.$$

Tout problème de maximisation se ramène donc à un problème de minimisation via une reformulation. Nous verrons d'autres exemples de reformulation, qui est une technique très utilisée pour transformer un problème en un autre problème équivalent mais que l'on saura mieux traiter théoriquement et/ou algorithmiquement.

Dans la majorité de ce cours, et notamment dans le reste de ce chapitre, on se concentrera sur des problèmes d'optimisation sans contraintes pour en caractériser plus précisément les solutions.

1.3.2 Solutions et minima

Soit le problème de minimisation sans contraintes

$$\underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimiser}} f(\mathbf{x}), \quad (1.3.4)$$

où $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

Une solution du problème d'optimisation (1.3.4) est un vecteur qui conduit à la meilleure valeur possible de l'objectif. Pour un problème de minimisation sans contraintes, cela correspond au concept de minimum global.

Définition 1.3.3 (Minimum global) Un point $\mathbf{x}^* \in \mathbb{R}^n$ est un **minimum global** du problème (1.3.4), ou plus simplement de la fonction objectif f , lorsque la propriété suivante est vérifiée :

$$\forall \mathbf{x} \in \mathbb{R}^n, \quad f(\mathbf{x}^*) \leq f(\mathbf{x}). \quad (1.3.5)$$

Lorsque l'inégalité est stricte pour $\mathbf{x} \neq \mathbf{x}^*$, ce minimum est unique.

Déterminer le minimum global d'une fonction est un problème difficile en général : il est donc courant d'utiliser une autre notion (plus faible) de solution, basée sur l'optimalité d'un point relativement à son voisinage.

Définition 1.3.4 (Minimum local) Un point $\mathbf{x}^* \in \mathbb{R}^n$ est un **minimum local** du problème (1.3.4), ou plus simplement de la fonction objectif f , lorsque la propriété suivante est vérifiée :

$$\exists \epsilon > 0, \forall \mathbf{x} \in \mathbb{R}^n, \quad \|\mathbf{x} - \mathbf{x}^*\| \leq \epsilon \Rightarrow f(\mathbf{x}^*) \leq f(\mathbf{x}). \quad (1.3.6)$$

Tout minimum global est ainsi un minimum local, mais l'inverse n'est pas vraie. De ce point de vue, il est donc plus aisé a priori de déterminer si un point est un minimum local que de déterminer s'il s'agit d'un minimum global. Néanmoins, en se basant sur la seule propriété (1.3.6), vérifier la minimalité locale requiert d'évaluer la fonction une infinité de fois. En pratique, on exploite les propriétés de la fonction à minimiser pour obtenir des conditions facilement vérifiables (à la main ou sur machine) qui caractérisent des minima locaux ou globaux. C'est ce que l'on décrit dans le reste de ce chapitre.

1.3.3 Conditions d'optimalité

Lorsqu'on cherche à minimiser une fonction f dérivable, il est possible de fournir des caractérisations pratiques de minima locaux (voire globaux) à l'aide des dérivées de f , qui fournissent une information locale sur la variation de la fonction. Ces caractérisations sont appelées **conditions d'optimalité**.

On s'intéresse d'abord aux fonctions dérivables, pour lesquelles on peut fournir une condition d'optimalité basée sur le gradient. Conformément à la suite du cours, nous donnerons le résultat dans le cas particulier des fonctions de classe $\mathcal{C}^1$.

Théorème 1.3.1 (Condition nécessaire d'optimalité à l'ordre 1) Soient $f \in \mathcal{C}^1(\mathbb{R}^d)$ et $\mathbf{w}^* \in \mathbb{R}^d$. Alors

$$[\mathbf{w}^* \text{ minimum local de } f] \implies \nabla f(\mathbf{w}^*) = 0. \quad (1.3.7)$$

Tout minimum local de f est donc un point en lequel le gradient de f s'annule, mais l'inverse n'est pas forcément vraie ! Comme son nom l'indique, cette condition est nécessaire mais pas suffisante : il peut en effet exister des points en lesquels le gradient s'annule sans qu'il s'agisse de minima. On parle alors de maxima locaux (ex : 0 pour la fonction $x \mapsto -x^2$) ou de points selles (ex : 0 pour $x \mapsto x^3$) : cette dernière catégorie pose notamment des problèmes en apprentissage profond, où les problèmes à résoudre possèdent souvent de nombreux points selles.

Plus globalement, si f est une fonction $\mathcal{C}^1$, un point $\mathbf{w}$ tel que $\nabla f(\mathbf{w}) = \mathbf{0}$ s'appelle un **point stationnaire d'ordre 1**.

Si l'on suppose que f est deux fois dérivable avec dérivée seconde continue, on peut alors établir des conditions d'optimalité plus fortes que celles à l'ordre un.

Théorème 1.3.2 (Condition nécessaire d'optimalité à l'ordre 2) Soient $f \in \mathcal{C}^2(\mathbb{R}^d)$ et $\mathbf{w}^* \in \mathbb{R}^d$. Alors

$$[\mathbf{w}^* \text{ minimum local de } f] \implies \begin{cases} \nabla f(\mathbf{w}^*) = \mathbf{0}, \\ \nabla^2 f(\mathbf{w}^*) \succeq \mathbf{0}. \end{cases} \quad (1.3.8)$$

La nouvelle propriété fait intervenir la dérivée à l'ordre 2, qui est une matrice : pour un minimum local, la matrice hessienne est nécessairement *semi-définie positive*.²

Comme pour l'ordre 1, il est possible qu'un point $\mathbf{w}^*$ vérifie $\nabla f(\mathbf{w}^*) = \mathbf{0}$ et $\nabla^2 f(\mathbf{w}^*) \succeq \mathbf{0}$ sans être un minimum local (voir 0 pour $w \mapsto w^3$ en dimension 1). Un point $\mathbf{w}$ que $\nabla f(\mathbf{w}) = \mathbf{0}$ et $\nabla^2 f(\mathbf{w}) \succeq \mathbf{0}$ s'appelle un **point stationnaire à l'ordre 2** : l'ensemble des points stationnaires d'ordre 2 contient l'ensemble des minima locaux, mais n'y est pas forcément égal.

Contrairement à l'ordre 1, l'ordre 2 permet de définir une version suffisante des conditions d'optimalité, qui permet de reconnaître un minimum local.

Théorème 1.3.3 (Condition suffisante d'optimalité à l'ordre 2) Soient $f \in \mathcal{C}^2(\mathbb{R}^d)$ et $\mathbf{w}^* \in \mathbb{R}^d$. Alors

$$\left. \begin{array}{l} \nabla f(\mathbf{w}^*) = \mathbf{0}, \\ \nabla^2 f(\mathbf{w}^*) \succ \mathbf{0}. \end{array} \right\} \implies [\mathbf{w}^* \text{ minimum local de } f]. \quad (1.3.9)$$

Il suffit donc que le gradient en un point soit nul et que la matrice hessienne en ce point soit définie positive³ pour que ce point soit un minimum local.

1.3.4 Cas des fonctions convexes

Nous considérons maintenant une classe de fonctions particulièrement intéressantes en optimisation : les fonctions convexes. Comme on le verra dans ce cours, il est possible de développer des algorithmes très efficaces pour minimiser des fonctions convexes. Dans la présente section, on s'intéresse aux propriétés des problèmes de minimisation impliquant une fonction convexe.

La convexité est une propriété au départ géométrique, qui s'applique à des ensembles.

Définition 1.3.5 (Ensemble convexe) Un ensemble $\mathcal{F} \subseteq \mathbb{R}^n$ est dit **convexe** si pour tout couple de points $\mathcal{F}$, le segment reliant ces deux points est inclus dans $\mathcal{F}$. Mathématiquement, cela s'écrit :

$$\forall (\mathbf{x}, \mathbf{v}) \in \mathcal{F}^2, \forall \alpha \in [0, 1], \quad \alpha \mathbf{x} + (1 - \alpha) \mathbf{v} \in \mathcal{F}. \quad (1.3.10)$$

²Une matrice symétrique $\mathbf{H} \in \mathbb{R}^{d \times d}$ est dite semi-définie positive si $\mathbf{v}^T \mathbf{H} \mathbf{v} \geq 0$ pour tout $\mathbf{v} \in \mathbb{R}^d$, ce que l'on note $\mathbf{H} \succeq \mathbf{0}$.

³Une matrice symétrique $\mathbf{H} \in \mathbb{R}^{d \times d}$ est dite définie positive si $\mathbf{v}^T \mathbf{H} \mathbf{v} > 0$ pour tout $\mathbf{v} \in \mathbb{R}^d$ non nul, ce que l'on note $\mathbf{H} \succ \mathbf{0}$.

Il est aussi possible de définir la convexité pour des fonctions.

Définition 1.3.6 (Fonction convexe) Une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est une **fonction convexe** sur un ensemble convexe $\mathcal{F} \subseteq \mathbb{R}^n$ si et seulement si

$$\forall (\mathbf{x}, \mathbf{v}) \in \mathcal{F}^2, \forall \alpha \in [0, 1], \quad f(\alpha \mathbf{x} + (1 - \alpha) \mathbf{v}) \leq \alpha f(\mathbf{x}) + (1 - \alpha) f(\mathbf{v}). \quad (1.3.11)$$

Exemple 1.3.1 (Fonctions convexes d'une variable)

1. La fonction $w \mapsto w^2$ est convexe sur $\mathbb{R}$.
2. La fonction $w \mapsto |w|$ est convexe sur $\mathbb{R}$.

Exemple 1.3.2 (Fonctions convexes en dimension d)

1. Si f est une norme sur $\mathbb{R}^n$, alors il s'agit d'une fonction convexe sur $\mathbb{R}^n$.
2. Une fonction quadratique $\mathbf{x} \mapsto \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x}$ avec $\mathbf{b} \in \mathbb{R}^n$ et $\mathbf{A} \in \mathbb{R}^{d \times d}$ semi-définie positive est convexe sur $\mathbb{R}^n$.

La notion de convexité est préservée par certaines opérations : en particulier, toute somme (et plus généralement toute combinaison linéaire à coefficients positifs) de fonctions convexes est une fonction convexe.

En plus de la définition (1.3.11), on peut caractériser la convexité au moyen des dérivées à l'ordre un et deux lorsque celles-ci existent.

Théorème 1.3.4 Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^1$ et $\mathcal{F} \subset \mathbb{R}^n$ un ensemble convexe. Alors, f est convexe sur $\mathcal{F}$ si et seulement si

$$\forall (\mathbf{x}, \mathbf{v}) \in \mathcal{F}^2, \quad f(\mathbf{v}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{v} - \mathbf{x}). \quad (1.3.12)$$

La propriété (1.3.12) joue un rôle fondamental en optimisation convexe.

Théorème 1.3.5 Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^2$ et $\mathcal{F} \subset \mathbb{R}^n$ un ensemble convexe. Alors, f est convexe sur $\mathbb{R}^n$ si et seulement si

$$\forall \mathbf{x} \in \mathcal{F}, \quad \nabla^2 f(\mathbf{x}) \succeq \mathbf{0}, \quad (1.3.13)$$

càd que la matrice hessienne en tout point de $\mathbb{R}^n$ est toujours semi-définie positive.

En termes d'optimisation, les fonctions convexes possèdent la propriété suivante, extrêmement intéressante du point de vue de l'optimisation.

Théorème 1.3.6 Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction convexe sur $\mathbb{R}^n$. Alors, on a les propriétés suivantes :

- i) Tout minimum local de f est un minimum global.
- ii) Si f est de classe $\mathcal{C}^1$, alors tout point $\mathbf{x}^*$ tel que $\nabla f(\mathbf{x}^*) = \mathbf{0}$ est un minimum global du problème.

1.3.5 Cas des fonctions fortement convexes

On peut définir une propriété encore plus puissante que la convexité, dont on verra qu'elle a un impact majeur sur les résultats d'optimisation. Il s'agit de la convexité forte, définie ci-dessous de trois manières, avec et sans dérivées.

Définition 1.3.7 (Fonction fortement convexe) Soit $\mathcal{F} \subset \mathbb{R}^n$ un ensemble convexe et $f : \mathbb{R}^n \rightarrow \mathbb{R}$. On dit que f est une fonction **fortement convexe** de paramètre $\mu > 0$, ou **μ -fortement convexe** sur $\mathcal{F}$, si et seulement si

$$\forall (\mathbf{x}, \mathbf{v}) \in \mathcal{F}^2, \forall \alpha \in [0, 1], \quad f(\alpha \mathbf{x} + (1 - \alpha)\mathbf{v}) \leq \alpha f(\mathbf{x}) + (1 - \alpha)f(\mathbf{v}) - \mu \frac{\alpha(1 - \alpha)}{2} \|\mathbf{v} - \mathbf{x}\|^2.$$

Théorème 1.3.7 Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^1$, $\mathcal{F} \subset \mathbb{R}^n$ un ensemble convexe et $\mu > 0$. La fonction f est μ -fortement convexe sur $\mathcal{F}$ si et seulement si

$$\forall (\mathbf{x}, \mathbf{v}) \in \mathcal{F}^2, \quad f(\mathbf{v}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{v} - \mathbf{x}) + \frac{\mu}{2} \|\mathbf{v} - \mathbf{x}\|^2. \quad (1.3.14)$$

Théorème 1.3.8 Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^2$, $\mathcal{F} \subset \mathbb{R}^n$ un ensemble convexe et $\mu > 0$. La fonction f est μ -fortement convexe sur $\mathcal{F}$ si et seulement si

$$\forall \mathbf{x} \in \mathcal{F}, \quad \nabla^2 f(\mathbf{x}) \succeq \mu \mathbf{I}_d.$$

Les fonctions fortement convexes offrent un contexte encore plus favorable pour l'optimisation que les fonctions convexes; la raison en incombe au résultat ci-dessous.

Théorème 1.3.9 Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est fortement convexe, elle possède un unique minimum global. De plus, si f est de classe $\mathcal{C}^1$, ce minimum est l'unique solution de $\nabla f(\mathbf{x}) = \mathbf{0}$.

1.4 Conclusion du chapitre 1

L'optimisation est un outil mathématique qui permet de modéliser de nombreux problèmes en sciences des données et au-delà. L'optimisation comporte toujours une phase de modélisation, qui consiste à formuler mathématiquement le problème en définissant une fonction objectif, des variables de décisions et des contraintes. Cela permet de placer le problème dans une classe, et ainsi de caractériser ce qu'est une solution de ce problème.

Dans un contexte d'optimisation continue, les concepts de dérivées et de convexité sont extrêmement utiles pour caractériser les solutions d'un problème donné.

Annexe A

Bases mathématiques

A.1 Éléments d'algèbre linéaire

Les fondements mathématiques de l'optimisation se trouvent dans l'analyse réelle, et en particulier dans le calcul différentiel. Les structures d'algèbre linéaire dans $\mathbb{R}^n$ jouent cependant un rôle prépondérant en optimisation (et en sciences des données). Cette section regroupe les résultats de base qui seront utilisés dans le cours.

Pour approfondir ces notions, on pourra consulter les liens suivants :

- <https://www.ceremade.dauphine.fr/~carlier/polyalgebre.pdf> (en français);
- <http://vmls-book.stanford.edu/vmls.pdf> (Chapitres 1 à 3, en anglais).

A.1.1 Algèbre linéaire vectorielle

On considèrera toujours l'espace des vecteurs $\mathbb{R}^n$ muni de sa structure d'espace vectoriel normé de dimension d . On définit donc les opérations suivantes :

- Pour tous $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, la somme des vecteurs $\mathbf{x}$ et $\mathbf{y}$ est notée $\mathbf{x} + \mathbf{y} = [x_i + y_i]_{1 \leq i \leq d}$;
- Pour tout $\lambda \in \mathbb{R}$, on définit $\lambda \mathbf{x} \stackrel{n}{=} \lambda \cdot \mathbf{x} = [\lambda x_i]_{1 \leq i \leq d}$. Dans ce contexte, un tel réel λ sera appelé un *scalaire*.

A l'aide de ces opérations, nous pouvons donc construire des **combinaisons linéaires** de vecteurs de $\mathbb{R}^n$ dont le résultat sera un vecteur de $\mathbb{R}^n$, à savoir des vecteurs de la forme $\sum_{i=1}^p \lambda_i \mathbf{x}_i$, où $\mathbf{x}_i \in \mathbb{R}^n$ et $\lambda_i \in \mathbb{R}$ pour tout $i = 1, \dots, p$.

Pour ce qui est de l'espace des matrices $\mathbb{R}^{n \times d}$, on peut également le munir d'une structure d'espace vectoriel normé de dimension nd . On définit donc les opérations suivantes :

- Pour tous $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times d}$, la somme des matrices $\mathbf{A}$ et $\mathbf{B}$ est notée $\mathbf{A} + \mathbf{B} = [\mathbf{A}_{ij} + \mathbf{B}_{ij}]_{\substack{1 \leq i \leq n \\ 1 \leq j \leq d}}$;
- Pour tout scalaire $\lambda \in \mathbb{R}$, on définit $\lambda \mathbf{A} \stackrel{n}{=} \lambda \cdot \mathbf{A} = [\lambda \mathbf{A}_{ij}]_{\substack{1 \leq i \leq n \\ 1 \leq j \leq d}}$.

Définition A.1.1 Un ensemble $S \subseteq \mathbb{R}^n$ vérifiant les conditions

1. $\mathbf{0}_d \in S$;

2. $\forall (\mathbf{x}, \mathbf{y}) \in \mathcal{S}, \mathbf{x} + \mathbf{y} \in \mathcal{S};$
3. $\forall \mathbf{x} \in \mathcal{S}, \forall \lambda \in \mathbb{R}, \lambda \mathbf{x} \in \mathcal{S}.$

s'appelle un sous-espace vectoriel de $\mathbb{R}^n$.

Définition A.1.2 Soient $\mathbf{x}_1, \dots, \mathbf{x}_p$ p vecteurs de $\mathbb{R}^n$. Le **sous-espace engendré** par les vecteurs $\mathbf{x}_1, \dots, \mathbf{x}_p$, noté $\text{vect}(\mathbf{x}_1, \dots, \mathbf{x}_p)$, est le sous-espace vectoriel

$$\text{vect}(\mathbf{x}_1, \dots, \mathbf{x}_p) := \left\{ \mathbf{x} = \sum_{i=1}^p \alpha_i \mathbf{x}_i \mid \alpha_i \in \mathbb{R} \forall i \right\}.$$

On rappelle ensuite les différentes propriétés notables des familles de vecteurs.

Définition A.1.3 • Une famille libre $\{\mathbf{x}_i\}_{i=1}^k$ de vecteurs de $\mathbb{R}^n$ est telle que les vecteurs sont linéairement indépendants : pour tous scalaires $\lambda_1, \dots, \lambda_k$ tels que $\sum_{i=1}^k \lambda_i \mathbf{x}_i = \mathbf{0}$, alors $\lambda_1 = \dots = \lambda_k = 0$. On a nécessairement $k \leq n$.

- Une famille liée est une famille de vecteurs qui n'est pas libre.
- Une famille génératrice de vecteurs de $\mathbb{R}^n$ est un ensemble de vecteurs $\{\mathbf{x}_i\}$ tel que le sous-espace engendré par ces vecteurs soit égal à $\mathbb{R}^n$.
- Une base de $\mathbb{R}^n$ est une famille de vecteurs $\{\mathbf{x}_i\}_{i=1}^n$ qui est à la fois libre et génératrice. Tout vecteur de $\mathbb{R}^n$ s'écrit alors de manière unique comme combinaison linéaire des $\mathbf{x}_i$. Toute base de $\mathbb{R}^n$ comporte exactement n vecteurs.

Comme la taille d'une base de $\mathbb{R}^n$ est n , on dit que cet espace vectoriel est de dimension n . En conséquence, la dimension d'un sous-espace vectoriel est au plus n .

Exemple A.1.1 Tout vecteur $\mathbf{x}$ de $\mathbb{R}^n$ s'écrit $\mathbf{x} = \sum_{i=1}^n x_i \mathbf{e}_i$, où $\mathbf{e}_i = [0 \dots 0 \ 1 \ 0 \dots 0]^T$ est le i -ème vecteur de la base canonique (le coefficient 1 se trouvant en i -ème position).

Norme et produit scalaire L'utilisation d'une norme, et du produit scalaire associé, permet de mesurer les distances entre vecteurs, ce qui sera particulièrement utile pour montrer la convergence d'une suite de points générés par un algorithme vers une solution d'un problème d'optimisation.

Définition A.1.4 La **norme euclidienne** $\|\cdot\|$ sur $\mathbb{R}^n$ est définie pour tout vecteur $\mathbf{x} \in \mathbb{R}^n$ par

$$\|\mathbf{x}\| := \sqrt{\sum_{i=1}^n x_i^2}.$$

Remarque A.1.1 Il s'agit bien d'une norme, car elle vérifie les quatres axiomes d'une norme :

1. $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|;$
2. $\|\mathbf{x}\| = 0 \Leftrightarrow \mathbf{x} = \mathbf{0}_{\mathbb{R}^n};$
3. $\forall \mathbf{x}, \|\mathbf{x}\| \geq 0;$

$$4. \forall \mathbf{x} \in \mathbb{R}^n, \forall \lambda \in \mathbb{R}, \|\lambda \mathbf{x}\| = |\lambda| \|\mathbf{x}\|.$$

On dira qu'un vecteur $\mathbf{x} \in \mathbb{R}^n$ est unitaire si $\|\mathbf{x}\| = 1$.

Définition A.1.5 Pour tous vecteurs $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, le **produit scalaire** dérivé de la norme euclidienne est une fonction de $\mathbf{x}$ et $\mathbf{y}$, notée $\mathbf{x}^T \mathbf{y}$, et définie par

$$\mathbf{x}^T \mathbf{y} := \sum_{i=1}^n x_i y_i.$$

Deux vecteurs $\mathbf{x}$ et $\mathbf{y}$ tels que $\mathbf{x}^T \mathbf{y} = 0$ seront dits orthogonaux.

On notera en particulier que $\mathbf{y}^T \mathbf{x} = \mathbf{x}^T \mathbf{y}$. Ce produit scalaire définit donc un “produit” entre un vecteur ligne et un vecteur colonne.

Proposition A.1.1 Soient $\mathbf{x}$ et $\mathbf{y}$ deux vecteurs de $\mathbb{R}^n$. Alors, on a les propriétés suivantes :

- i) $\|\mathbf{x} + \mathbf{y}\|^2 = \|\mathbf{x}\|^2 + 2\mathbf{x}^T \mathbf{y} + \|\mathbf{y}\|^2$;
- ii) $\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x}\|^2 - 2\mathbf{x}^T \mathbf{y} + \|\mathbf{y}\|^2$;
- iii) $\|\mathbf{x}\|^2 + \|\mathbf{y}\|^2 = \frac{1}{4} (\|\mathbf{x} + \mathbf{y}\|^2 + \|\mathbf{x} - \mathbf{y}\|^2)$;
- iv) **Inégalité de Cauchy-Schwarz :**

$$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \quad \mathbf{x}^T \mathbf{y} \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Remarque A.1.2 La dernière inégalité est un résultat très important, qui s'utilise aussi bien en algèbre linéaire qu'en analyse fonctionnelle. Comme on le verra, elle apparaît également dans la preuve des inégalités de Taylor, qui sont fondamentales en optimisation.

A.1.2 Algèbre linéaire matricielle

Sur les espaces matriciels, on définit également un produit matriciel entre matrices de dimensions compatibles. Pour toutes matrices $\mathbf{A} \in \mathbb{R}^{m \times n}$ et $\mathbf{B} \in \mathbb{R}^{n \times p}$, la matrice produit $\mathbf{AB}$ est définie comme la matrice $\mathbf{C} \in \mathbb{R}^{m \times p}$ telle que

$$\forall i = 1, \dots, m, \forall j = 1, \dots, p, \quad C_{ij} = \sum_{k=1}^n A_{ik} B_{kj}.$$

Par analogie, le produit d'une matrice $\mathbf{A} \in \mathbb{R}^{m \times n}$ avec un vecteur $\mathbf{x} \in \mathbb{R}^n$ sera le vecteur $\mathbf{y} \in \mathbb{R}^m$ donné par

$$\forall i = 1, \dots, m, \quad y_i = \sum_{j=1}^n A_{ij} x_j.$$

Remarque A.1.3 On notera que la notation du produit scalaire sur $\mathbb{R}^n$ correspond au produit de deux matrices de taille $1 \times n$ et $n \times 1$, dont le résultat est une matrice 1×1 , c'est-à-dire un scalaire.

Lorsque l'on travaille avec des matrices, on s'intéresse généralement aux sous-espaces définis ci-dessous.

Définition A.1.6 (Sous-espaces matriciels) Soit une matrice $A \in \mathbb{R}^{m \times n}$, on définit les deux sous-espaces suivants :

- Le noyau de A est le sous-espace vectoriel

$$\ker(A) := \{x \in \mathbb{R}^n \mid Ax = 0_m\}$$

- L'image de A est le sous-espace vectoriel

$$\text{Im}(A) := \{y \in \mathbb{R}^m \mid \exists x \in \mathbb{R}^n, y = Ax\}$$

La dimension de ce sous-espace vectoriel s'appelle le **rang** de A . On la note $\text{rang}(A)$ et on a $\text{rang}(A) \leq \min\{m, n\}$.

Théorème A.1.1 (Théorème du rang) Pour toute matrice $A \in \mathbb{R}^{m \times n}$, on a

$$\dim(\ker(A)) + \text{rang}(A) = n.$$

Définition A.1.7 (Normes matricielles) On définit sur $\mathbb{R}^{m \times n}$ la norme d'opérateur $\|\cdot\|$ et la norme de Frobenius $\|\cdot\|_F$ par

$$\forall A \in \mathbb{R}^{m \times n}, \begin{cases} \|A\| &:= \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0_n}} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\| \\ \|A\|_F &:= \sqrt{\sum_{1 \leq i \leq m, 1 \leq j \leq n} A_{ij}^2}. \end{cases}$$

Définition A.1.8 (Matrice symétrique) Une matrice carrée $A \in \mathbb{R}^{n \times n}$ est dite **symétrique** si elle vérifie $A^T = A$.

L'ensemble des matrices symétriques de taille $n \times n$ sera noté S^n .

Définition A.1.9 (Matrice inversible) Une matrice carrée $A \in \mathbb{R}^{n \times n}$ est dite **inversible** s'il existe $B \in \mathbb{R}^{n \times n}$ telle que $BA = AB = I_n$ (où l'on rappelle que I_n désigne la matrice identité de $\mathbb{R}^{n \times n}$).

Si elle existe, une telle matrice B est unique : elle est appelée **l'inverse de A** et on la note A^{-1} .

Définition A.1.10 (Matrice (semi-)définie positive) Une matrice carrée $A \in \mathbb{R}^{n \times n}$ symétrique est dite **semi-définie positive** si

$$\forall x \in \mathbb{R}^n, \quad x^T A x \geq 0,$$

ce que l'on notera $A \succeq 0$.

Une telle matrice est dite **définie positive** lorsque $x^T A x > 0$ pour tout vecteur x non nul, ce que l'on notera $A \succ 0$.

Définition A.1.11 (Matrice orthogonale) Une matrice carrée $P \in \mathbb{R}^{n \times n}$ est dite **orthogonale** si $P^T = P^{-1}$.

Par extension, on dira que $Q \in \mathbb{R}^{m \times n}$ avec $m \leq n$ est orthogonale si $QQ^T = I_m$ (les colonnes de Q sont donc orthonormées dans $\mathbb{R}^m$).

On notera que lorsque $Q \in \mathbb{R}^{n \times n}$ est une matrice orthogonale, alors sa transposée Q^T est également orthogonale (ce résultat n'est pas vrai pour une matrice rectangulaire). On utilisera fréquemment la propriété des matrices orthogonales énoncée ci-dessous.

Lemme A.1.1 Soit une matrice $A \in \mathbb{R}^{m \times n}$ et $U \in \mathbb{R}^{m \times m}$, $V \in \mathbb{R}^{n \times n}$ des matrices orthogonales, respectivement de $\mathbb{R}^{m \times m}$ et $\mathbb{R}^{n \times n}$. On a

$$\|A\| = \|UA\| = \|AV\| \quad \text{et} \quad \|A\|_F = \|UA\|_F = \|AV\|_F,$$

c'est-à-dire que la multiplication par une matrice orthogonale ne modifie pas la norme d'opérateur.

Par corollaire immédiat du lemme précédent, on note qu'une matrice $Q \in \mathbb{R}^{m \times n}$ orthogonale avec $m \leq n$ vérifie nécessairement $\|Q\| = 1$ et $\|Q\|_F = \sqrt{m}$.

Définition A.1.12 (Valeur propre) Soit une matrice $A \in \mathbb{R}^{n \times n}$. On dit que $\lambda \in \mathbb{R}$ est une **valeur propre de A** si

$$\exists v \in \mathbb{R}^n, v \neq 0_n, \quad Av = \lambda v.$$

Le vecteur v est appelé un **vecteur propre associé à la valeur propre λ** . L'ensemble des valeurs propres de A s'appelle le **spectre de A**.

Le sous-espace engendré par les vecteurs propres associés à la même valeur propre d'une matrice s'appelle un sous-espace propre. Sa dimension correspond à l'ordre de multiplicité de la valeur propre relativement à la matrice.

Proposition A.1.2 Pour toute matrice $A \in \mathbb{R}^{n \times n}$, on a les propriétés suivantes :

- La matrice A possède n valeurs propres complexes mais pas nécessairement réelles.
- Si la matrice A est semi-définie positive (respectivement définie positive), alors ses valeurs propres sont réelles positives (respectivement strictement positives).
- Le noyau de A est engendré par les vecteurs propres associés à la valeur propre 0.

Théorème A.1.2 (Théorème spectral) Toute matrice carrée $A \in \mathbb{R}^{n \times n}$ symétrique admet une décomposition dite **spectrale** de la forme :

$$A = P\Lambda P^{-1},$$

où $P \in \mathbb{R}^{n \times n}$ est une matrice orthogonale, dont les colonnes $p_1, \dots, p_n$ forment une base orthonormée de vecteurs propres, et $\Lambda \in \mathbb{R}^{n \times n}$ est une matrice diagonale qui contient les n valeurs propres de A $\lambda_1, \dots, \lambda_n$ sur la diagonale.

Il est à noter que la décomposition spectrale n'est pas unique. En revanche, l'ensemble des valeurs propres est unique, que l'on prenne en compte les ordres de multiplicité ou non.

Géométriquement parlant, on voit ainsi que, pour tout vecteur $x \in \mathbb{R}^n$ décomposé dans la base des p_i que l'on multiplie par A , les composantes de ce vecteur associées aux plus grandes valeurs propres¹ seront augmentées, tandis que celles associées aux valeurs propres de petite magnitude seront réduites (voire annihilées dans le cas d'une valeur propre nulle).

¹On parle ici de plus grandes valeurs propres en valeur absolue, ou magnitude.