

Réponses aux questions

I) Création d'un tableau de bord

1. La table EMPLOYEES_CLEAN possède 647 lignes et 14 colonnes
2. A. Les 3 jobs avec au moins 100 employés sont Sales Rep I, Sales Rep II et Sales Rep III
B. Le mois avec le plus d'anniversaires est le mois de janvier
3. Le Danemark a le profit moyen le plus bas (30 493, 46\$) et l'Allemagne a le profit moyen le plus élevé (101 306, 73\$)

Le Danemark a le nombre d'employés le plus bas (37) et les Etats-Unis ont le nombre d'employés le plus élevé (123)

Avec 68 employés, la Grande Bretagne a un profit moyen de 89 351, 04\$

4. La 5^{ème} classe contient le plus d'employés, les bornes sont : 26 250\$ - 27 750\$

II) Implémentation des modèles de Machine Learning

Le modèle champion : Gradient Boosting car il est le champion sur tous les indicateurs sauf le score F1 où le vainqueur est le réseau de neurone qui est le pire modèle sur tous les autres indicateurs


Nom de l'algorithme	Gain	Gini	KS (Youden)	Lift	Score F1	Taux de mauvaise classification
Gradient Boosting	0,8557	0,4846	0,3488	1,8557	0,6643	0,3256
Forêt	0,4105	0,2177	0,1551	1,4105	0,4095	0,4327
Régression logistique	0,396	0,2501	0,1863	1,396	0,6352	0,4056
Réseau neuronal	-0,3163	0	0	0,6837	0,6884	0,4751
Arbre de décision	0,5704	0,2351	0,1639	1,5704	0,5799	0,418
Champion	Gradient Boosting	Gradient Boosting	Gradient Boosting	Gradient Boosting	Réseau neuronal	Gradient Boosting

La formule pour calculer le retour sur investissement (ROI) pour 10 000 clients est :

$$\text{ROI} = 10\,000 * \text{centile} * (-2\text{€} + 3\text{€} * 50\% * \text{modèle cumulé})$$

Centile	Observations	Evénements	Modèle	Best	Modèle cumulé	Best cumulé	ROI
5,00	5556	4931	3,5829	4,0371	3,5829	4,0371	1239,3279
10,00	5556	3971	2,8854	4,0371	3,2342	4,0371	2042,6885
15,00	5556	3202	2,3266	4,0371	2,9316	4,0371	2496,8211
20,00	5556	2695	1,9582	4,0371	2,6883	4,0371	2720,7084
25,00	5556	2151	1,5629	3,8518	2,4632	4,0000	2697,5477
30,00	5556	1640	1,1914	0,0000	2,2512	3,3333	2442,1435
35,00	5556	1650	1,1992	0,0000	2,1009	2,8571	2191,644
40,00	5556	1234	0,8969	0,0000	1,9504	2,5000	1752,195
45,00	5556	1066	0,7743	0,0000	1,8198	2,2222	1236,149
50,00	5556	985	0,7157	0,0000	1,7094	2,0000	683,46957
55,00	5556	835	0,6067	0,0000	1,6091	1,8182	62,6703
60,00	5556	735	0,5341	0,0000	1,5195	1,6667	-603,5422
65,00	5556	624	0,4531	0,0000	1,4375	1,5385	-1320,345
70,00	5556	500	0,3636	0,0000	1,3608	1,4286	-2093,097
75,00	5556	426	0,3095	0,0000	1,2907	1,3333	-2899,637
80,00	5556	325	0,2361	0,0000	1,2248	1,2500	-3752,044
85,00	5556	231	0,1676	0,0000	1,1626	1,1765	-4647,29
90,00	5556	194	0,1412	0,0000	1,1059	1,1111	-5559,037
95,00	5556	85	0,0618	0,0000	1,0509	1,0526	-6520,436
100,00	5551	45	0,0327	0,0000	1,0000	1,0000	-7500

On obtient le graphique suivant :



Si l'on sélectionne les 25% ayant la probabilité la plus forte d'acheter d'après notre modèle, le ROI serait de 90 589, 98€ pour 10 000 clients

III) Programmation

1. Ecrire un programme qui permet de créer une copie de la table sashelp.shoes vous appellerez **copieshoes** cette table.

```
data copieshoes;
set sashelp.shoes;
run;
```

2. Faire un affichage des 15 premières observations avec la procédure Appropiee.

```
proc print data=copieshoes(obs=15);
run;
```

Obs.	Region	Product	Subsidiary	Stores	Sales	Inventory	Returns
1	Africa	Boot	Addis Ababa	12	\$29,761	\$191,821	\$769
2	Africa	Men's Casual	Addis Ababa	4	\$67,242	\$118,036	\$2,284
3	Africa	Men's Dress	Addis Ababa	7	\$76,793	\$136,273	\$2,433
4	Africa	Sandal	Addis Ababa	10	\$62,819	\$204,284	\$1,861
5	Africa	Slipper	Addis Ababa	14	\$68,641	\$279,795	\$1,771
6	Africa	Sport Shoe	Addis Ababa	4	\$1,690	\$16,634	\$79
7	Africa	Women's Casual	Addis Ababa	2	\$51,541	\$98,641	\$940
8	Africa	Women's Dress	Addis Ababa	12	\$108,942	\$311,017	\$3,233
9	Africa	Boot	Algiers	21	\$21,297	\$73,737	\$710
10	Africa	Men's Casual	Algiers	4	\$63,206	\$100,982	\$2,221
11	Africa	Men's Dress	Algiers	13	\$123,743	\$428,575	\$3,621
12	Africa	Sandal	Algiers	25	\$29,198	\$84,447	\$1,530
13	Africa	Slipper	Algiers	17	\$64,891	\$248,198	\$1,823
14	Africa	Sport Shoe	Algiers	9	\$2,617	\$9,372	\$168
15	Africa	Women's Dress	Algiers	12	\$90,648	\$266,805	\$2,690

3. Ecrire un programme qui permet de créer une copie de la table sashelp.shoes vous appellerez **shoes_sql** cette table.

```
proc sql;
create table shoes_sql as select s.* from sashelp.shoes s;
quit;
```

4. Faire un affichage des 15 premières observations avec une procédure SQL en prenant le soin d'afficher le numéro d'observation

```
proc sql number outobs=15;
select * from shoes_sql;
quit;
```

Obs.	Region	Product	Subsidiary	Stores	Sales	Inventory	Returns
1	Africa	Boot	Addis Ababa	12	\$29,761	\$191,821	\$769
2	Africa	Men's Casual	Addis Ababa	4	\$67,242	\$118,036	\$2,284
3	Africa	Men's Dress	Addis Ababa	7	\$76,793	\$136,273	\$2,433
4	Africa	Sandal	Addis Ababa	10	\$62,819	\$204,284	\$1,861
5	Africa	Slipper	Addis Ababa	14	\$68,641	\$279,795	\$1,771
6	Africa	Sport Shoe	Addis Ababa	4	\$1,690	\$16,634	\$79
7	Africa	Women's Casual	Addis Ababa	2	\$51,541	\$98,641	\$940
8	Africa	Women's Dress	Addis Ababa	12	\$108,942	\$311,017	\$3,233
9	Africa	Boot	Algiers	21	\$21,297	\$73,737	\$710
10	Africa	Men's Casual	Algiers	4	\$63,206	\$100,982	\$2,221
11	Africa	Men's Dress	Algiers	13	\$123,743	\$428,575	\$3,621
12	Africa	Sandal	Algiers	25	\$29,198	\$84,447	\$1,530
13	Africa	Slipper	Algiers	17	\$64,891	\$248,198	\$1,823
14	Africa	Sport Shoe	Algiers	9	\$2,617	\$9,372	\$168
15	Africa	Women's Dress	Algiers	12	\$90,648	\$266,805	\$2,690

5. Écrire un programme SAS qui permet de sélectionner les différentes régions avec une PROC SQL

```
proc sql;
select distinct region from shoes_sql;
quit;
```

Region
Africa
Asia
Canada
Central America/Caribbean
Eastern Europe
Middle East
Pacific
South America
United States
Western Europe

6. Quels sont les différents produits vendus en Afrique

```
proc sql;
select distinct region, product from shoes_sql where region="Africa";
quit;
```

Region	Product
Africa	Boot
Africa	Men's Casual
Africa	Men's Dress
Africa	Sandal
Africa	Slipper
Africa	Sport Shoe
Africa	Women's Casual
Africa	Women's Dress

7. Quels sont les sommes totales des ventes effectuées au format dollar12. dans chaque Région

```
proc sql;
select region, sum(sales) FORMAT=dollar12. as Sales from shoes_sql group by region;
quit;
```

Region	Sales
Africa	\$2,342,588
Asia	\$460,231
Canada	\$4,255,712
Central America/Caribbean	\$3,657,753
Eastern Europe	\$2,394,940
Middle East	\$5,631,779
Pacific	\$2,296,794
South America	\$2,434,783
United States	\$5,503,986
Western Europe	\$4,873,000

8. Dans quelle région il y a eu le plus de ventes.

```
proc sql outobs=1;
select region, sum(sales) FORMAT=dollar12. as Sales from shoes_sql group by region order
by Sales desc;
quit;
```

Region	Sales
Middle East	\$5,631,779

9. Écrire un programme qui affiche les produits dont les ventes totales effectues atteignent 4000 000\$ à l'aide d'une procédure SQL

```
proc sql;
select product, sum(sales) FORMAT=dollar12. as Sales from shoes_sql group by product
having Sales >= 4000000;
quit;
```

Product	Sales
Men's Casual	\$7,933,707
Men's Dress	\$5,507,243
Slipper	\$6,175,834
Women's Casual	\$4,137,861
Women's Dress	\$6,226,475

10. Quel est le produit le plus vendu

```
proc sql outobs=1;
select product, sum(sales) FORMAT=dollar12. as Sales from shoes_sql group by product
order by Sales desc;
quit;
```

Product	Sales
Men's Casual	\$7,933,707